

CONSUMO DE MÍDIA TRADICIONAL E DIGITAL NO BRASIL: Uma análise de mineração de dados e dos hábitos de informação

Edinéia Silva¹

Sara Bioto²

RESUMO

O avanço da internet e das plataformas digitais transformou significativamente a forma como a população brasileira consome informação. Apesar disso, meios tradicionais, como televisão e rádio, permanecem presentes no cotidiano da sociedade, configurando um cenário híbrido de consumo midiático. Este estudo utiliza técnicas de mineração de dados para identificar padrões de consumo de mídias tradicionais e digitais nos domicílios brasileiros. A pesquisa foi desenvolvida com base nos microdados da TIC Domicílios 2025, produzida pelo CETIC.br/CGI.br, e em indicadores do Reuters Digital News Report 2025. A metodologia seguiu o modelo CRISP-DM, contemplando etapas de preparação, modelagem e validação dos dados. Foram aplicados os algoritmos K-Means e Apriori, além do Clustering Hierárquico Ward como técnica complementar de validação. Os resultados permitiram identificar quatro perfis de consumo de mídia: Tradicional Puro, Digital Urbano, Digital Rural e Digital Premium. As regras de associação evidenciaram forte relação entre renda, escolaridade, acesso à internet e uso de plataformas digitais. Os achados demonstram que o Brasil vive uma transição midiática marcada pela coexistência entre meios tradicionais e digitais, ainda acompanhada por desigualdades de acesso à informação. O estudo reforça o potencial da mineração de dados como ferramenta de análise social e comunicacional.

Palavras-chave: Mineração de Dados. K-Means. Apriori. Consumo de mídia. Inclusão digital.

ABSTRACT

The expansion of the internet and digital platforms has significantly transformed the way the Brazilian population consumes information. Nevertheless, traditional media such as television and radio remain part of everyday life, creating a hybrid media consumption environment. This study applies data mining techniques to identify patterns of traditional and digital media consumption in Brazilian households. The research was based on microdata from the TIC Domicílios 2025 survey, produced by CETIC.br/CGI.br, and indicators from the Reuters Digital News Report 2025. The methodology followed the CRISP-DM framework, including data preparation, modeling, and validation stages. The K-Means and Apriori algorithms were applied, while Hierarchical Ward Clustering was used as a complementary validation technique. The results identified four media consumption profiles: Traditional Pure, Urban Digital, Rural Digital, and Premium Digital. Association rules revealed strong relationships between income, education level, internet access, and digital platform usage. The findings indicate that Brazil is experiencing a media transition characterized by the coexistence of traditional and digital

¹ Aluna do curso de Inteligência Artificial (IA), da FATEC de Rio Claro. E-mail: edineia.silva@aluno.cps.sp.gov.br

² Aluna do curso de Inteligência Artificial (IA), da FATEC de Rio Claro. E-mail: sara.simoes@aluno.cps.sp.gov.br

media, alongside persistent inequalities in access to information. The study highlights the potential of data mining as a tool for social and communication analysis.

Keywords: Data Mining. K-Means. Apriori. Media consumption. Digital inclusion.

1. INTRODUÇÃO

Nas últimas décadas, o avanço das tecnologias digitais transformou significativamente a forma como a sociedade produz, consome e compartilha informações. A expansão da internet, acompanhada pela popularização dos smartphones e das redes sociais, modificou os hábitos de comunicação da população brasileira e ampliou o acesso a conteúdos digitais.

Durante grande parte do século XX, meios tradicionais como televisão, rádio e jornais impressos exerceram papel central na circulação de informações e na formação da opinião pública. Entretanto, o crescimento das plataformas digitais ampliou a descentralização informacional, permitindo que conteúdos fossem produzidos e compartilhados por diferentes atores em ambientes conectados. Segundo Castells (2009), a sociedade contemporânea passou a operar em uma lógica estruturada por redes digitais de comunicação, caracterizando a chamada “sociedade em rede”.

No Brasil, essa transformação ocorre de maneira heterogênea. Ao mesmo tempo em que plataformas como YouTube, Instagram e WhatsApp se consolidaram como importantes fontes de informação, os meios tradicionais continuam ocupando espaço relevante no cotidiano da população. Jenkins (2009) define esse fenômeno como convergência midiática, em que diferentes meios coexistem e disputam atenção simultaneamente.

Além disso, a expansão das redes sociais intensificou a circulação rápida e fragmentada de conteúdos digitais. Santaella (2003) destaca que a cibercultura inaugurou um modelo comunicacional marcado pela conectividade contínua e pela personalização do consumo informacional. Apesar desse avanço, o Brasil ainda apresenta desigualdades relevantes relacionadas à renda, escolaridade, infraestrutura tecnológica e acesso à internet.

Nesse contexto, técnicas de mineração de dados tornam-se ferramentas importantes para compreender padrões de comportamento informacional em grandes bases populacionais. Segundo Han, Kamber e Pei (2011), a mineração de dados permite identificar relações, agrupamentos e tendências em conjuntos complexos de informações.

Diante desse cenário, este estudo busca analisar padrões de consumo de mídia tradicional e digital no Brasil por meio de técnicas de mineração de dados aplicadas aos microdados da pesquisa TIC Domicílios 2025 e aos indicadores do Reuters Digital News Report 2025. Para isso, foram utilizados algoritmos de aprendizado não supervisionado, como K-Means, Clustering Hierárquico e Apriori, com o objetivo de identificar perfis de consumo de mídia e relações entre conectividade digital, plataformas utilizadas e características socioeconômicas da população brasileira. A pesquisa procura responder às seguintes questões centrais:

- I – Qual o nível de presença de mídias tradicionais e digitais nos lares brasileiros?
- II – Quais plataformas concentram o consumo de notícias?
- III – Como fatores sociais influenciam o acesso à informação digital?
- IV – Quais padrões comportamentais podem ser identificados por meio da mineração de dados?

2. OBJETIVOS

2.1 Objetivo geral

Aplicar técnicas de mineração de dados não supervisionada para identificar e segmentar padrões de consumo de mídia da população brasileira, considerando aspectos de conectividade digital, infraestrutura tecnológica e perfil socioeconômico dos domicílios.

2.2 Objetivos específicos

- a) Analisar a infraestrutura tecnológica dos domicílios brasileiros, considerando a presença de mídias tradicionais e dispositivos digitais de acesso à internet.
- b) Identificar os principais hábitos de consumo informacional da população, comparando mídias tradicionais, plataformas digitais e redes sociais.
- c) Avaliar a relação entre plataformas digitais, credibilidade da informação e preocupação com desinformação e fake news.
- d) Investigar como renda e escolaridade influenciam o acesso à internet, à infraestrutura tecnológica e ao consumo de mídia digital.

e) Aplicar o algoritmo K-Means para segmentar perfis de consumo de mídia e utilizar o método Hierárquico Ward na validação dos agrupamentos.

f) Implementar o algoritmo Apriori para identificar padrões de associação entre conectividade digital, consumo de mídia e perfil socioeconômico.

3. JUSTIFICATIVA

O consumo de mídia no Brasil passa por um processo de transformação impulsionado pela expansão das plataformas digitais, redes sociais e aplicativos de mensagens, que modificaram os hábitos de acesso à informação e a relação da população com os meios tradicionais de comunicação. Apesar do avanço da conectividade, ainda existem desigualdades significativas no acesso à internet e às tecnologias digitais. Enquanto parte da população possui acesso contínuo a múltiplos dispositivos, outra ainda depende predominantemente da televisão e do rádio para se informar.

Nesse contexto, compreender os diferentes perfis de consumo midiático e os fatores sociais associados a essas diferenças torna-se relevante para subsidiar discussões sobre inclusão digital, combate à desinformação e democratização do acesso à informação. Além da relevância social, o estudo também possui importância acadêmica e tecnológica ao demonstrar a aplicação prática de técnicas de mineração de dados em uma base nacional de grande porte. O uso combinado dos algoritmos K-Means, Apriori e Clustering Hierárquico evidencia o potencial da Inteligência Artificial na análise de padrões sociais e comunicacionais.

4. REFERENCIAL TEÓRICO

4.1 Mineração de dados e descoberta de conhecimento

A mineração de dados pode ser definida como o processo de identificação de padrões, tendências e relações relevantes em grandes volumes de dados. Essa área integra conceitos de estatística, aprendizado de máquina, bancos de dados e inteligência artificial com o objetivo de transformar dados brutos em conhecimento útil para análise e tomada de decisão. Segundo Han, Kamber e Pei (2011), a mineração de dados constitui uma das etapas centrais do processo conhecido como KDD (Knowledge Discovery in Databases), responsável pela descoberta de conhecimento em bases de dados. Esse processo envolve etapas de seleção, limpeza, transformação, modelagem e interpretação dos dados analisados.

Fayyad et al. (1996) afirmam que o KDD representa um processo iterativo e não trivial de identificação de padrões válidos, novos e potencialmente úteis em grandes conjuntos de dados. Nesse contexto, a mineração de dados atua como mecanismo capaz de revelar relações dificilmente perceptíveis por análises estatísticas convencionais. Entre as principais tarefas da mineração de dados destacam-se: classificação, regressão, agrupamento, detecção de anomalias e regras de associação. Neste trabalho, foram utilizadas principalmente técnicas de aprendizado não supervisionado, nas quais os algoritmos buscam identificar estruturas naturais nos dados sem categorias previamente definidas.

4.2 Consumo de mídia e sociedade em rede

A transformação digital modificou profundamente os processos de comunicação contemporâneos. O avanço das redes digitais descentralizou a circulação da informação e alterou a relação da sociedade com os meios tradicionais de comunicação. Castells (2009) define esse cenário como sociedade em rede, caracterizada por fluxos digitais de informação e comunicação conectados globalmente.

A expansão das redes sociais intensificou essa dinâmica, fazendo com que plataformas digitais passassem a atuar simultaneamente como meios de entretenimento, interação social e circulação de notícias. Segundo Lévy (1999), o ciberespaço ampliou as possibilidades de construção coletiva do conhecimento, permitindo que os indivíduos atuassem tanto como consumidores quanto como produtores de informação.

No Brasil, o crescimento de plataformas como WhatsApp, YouTube e Instagram modificou significativamente o comportamento informacional da população. O acesso às notícias tornou-se mais instantâneo, descentralizado e mediado por algoritmos de recomendação. Entretanto, essa transformação não eliminou os meios tradicionais. Jenkins (2009) argumenta que a convergência midiática ocorre pela coexistência entre diferentes plataformas de comunicação, e não pela substituição completa das tecnologias anteriores. Esse comportamento híbrido mostra-se especialmente relevante no contexto brasileiro, onde televisão, rádio e internet continuam coexistindo em grande parte dos domicílios.

4.3 Cibercultura e plataformas digitais

O avanço das tecnologias digitais provocou mudanças culturais significativas na forma como a sociedade produz e consome conteúdos. Segundo Santaella (2003), a cibercultura introduziu uma lógica comunicacional marcada pela hiperconectividade, mobilidade e fragmentação das mensagens. Nesse contexto, os usuários passam a consumir conteúdos em múltiplas plataformas simultaneamente, muitas vezes de forma personalizada e sob demanda.

O crescimento do YouTube como fonte de informação exemplifica essa transformação, evidenciando a centralidade do conteúdo audiovisual no consumo midiático contemporâneo. Além disso, aplicativos de mensagens instantâneas, como WhatsApp, ampliaram a velocidade de circulação das informações e facilitaram o compartilhamento de conteúdos em redes privadas e descentralizadas.

Segundo Castells (2009), esse processo caracteriza a comunicação de massa autoprogramada, na qual indivíduos conseguem produzir e distribuir conteúdos em larga escala sem depender diretamente das estruturas tradicionais da mídia. Entretanto, essa descentralização também amplia desafios relacionados à desinformação, à circulação de notícias falsas e à fragmentação da esfera pública.

4.4 Algoritmo K-Means

O algoritmo K-Means é uma das técnicas de agrupamento mais utilizadas em mineração de dados e aprendizado de máquina. Proposto por MacQueen (1967), o método busca dividir os dados em grupos homogêneos, denominados clusters, minimizando a distância entre os elementos pertencentes a um mesmo agrupamento.

O funcionamento do algoritmo baseia-se na definição de centróides, responsáveis por representar o centro geométrico de cada grupo. Os registros são associados ao cluster cujo centróide apresenta menor distância em relação às suas características. Segundo Han, Kamber e Pei (2011), o K-Means apresenta elevada eficiência computacional e grande utilidade na análise exploratória de bases extensas. Neste estudo, o algoritmo foi utilizado para identificar perfis de consumo de mídia entre os domicílios brasileiros.

4.5 Regras de Associação e Algoritmo Apriori

As regras de associação são técnicas utilizadas para identificar relações frequentes entre variáveis em grandes conjuntos de dados. O algoritmo Apriori, desenvolvido por Agrawal e

Srikant (1994), é um dos métodos mais conhecidos para esse tipo de análise, permitindo identificar padrões recorrentes de coocorrência entre elementos presentes na base de dados.

As principais métricas utilizadas são suporte, confiança e lift. O suporte mede a frequência de ocorrência da regra na base de dados; a confiança representa a probabilidade de ocorrência do consequente quando o antecedente está presente; e o lift avalia a força da associação entre os elementos analisados. Valores de lift superiores a 1 indicam associação positiva entre variáveis. Neste trabalho, o Apriori foi utilizado para identificar relações entre infraestrutura tecnológica, renda, escolaridade e hábitos de consumo de mídia digital.

4.6 Clustering Hierárquico e método Ward

O Clustering Hierárquico é uma técnica de agrupamento baseada na construção progressiva de estruturas hierárquicas de similaridade. Diferentemente do K-Means, o método hierárquico não exige definição prévia do número de grupos, permitindo visualizar as relações entre os dados por meio de dendrogramas.

O método Ward busca minimizar a variância interna dos agrupamentos, produzindo clusters mais homogêneos. Neste estudo, essa técnica foi utilizada como mecanismo complementar de validação dos agrupamentos encontrados pelo K-Means, permitindo avaliar a estabilidade estrutural dos clusters identificados.

5. METODOLOGIA

Este estudo possui caráter quantitativo, exploratório e aplicado, utilizando técnicas de mineração de dados para identificar padrões de consumo de mídia no Brasil. A pesquisa foi estruturada com base na metodologia CRISP-DM, amplamente utilizada em projetos de ciência de dados por organizar o processo analítico em etapas iterativas.

A pesquisa envolveu procedimentos de análise exploratória, tratamento de valores ausentes e pré-processamento de 25.233 registros válidos da pesquisa TIC Domicílios. Na etapa de modelagem, foram aplicados os algoritmos K-Means e Hierárquico de Ward para geração e validação dos clusters, além do algoritmo Apriori para extração de regras de associação. Segundo Chapman et al. (2000), o CRISP-DM possui natureza cíclica, permitindo revisões e ajustes ao longo do processo analítico, o que contribui para a robustez da pesquisa.

5.1 Bases de dados utilizadas

A principal fonte de dados utilizada nesta pesquisa foi a TIC Domicílios 2025, produzida pelo Centro Regional de Estudos para o Desenvolvimento da Sociedade da Informação (CETIC.br), vinculado ao Comitê Gestor da Internet no Brasil (CGI.br). A pesquisa reúne informações relacionadas à infraestrutura tecnológica, acesso à internet, utilização de dispositivos digitais e hábitos de consumo de mídia nos domicílios brasileiros.

De forma complementar, também foram utilizados indicadores do Reuters Digital News Report 2025, especialmente aqueles relacionados ao consumo de notícias em plataformas digitais e redes sociais. O Quadro 1 apresenta as principais bases de dados utilizadas no desenvolvimento da pesquisa, bem como o volume de registros analisados e as instituições responsáveis pela produção dos dados.

Quadro 1 – Bases de dados utilizadas no projeto de MD

Base de Dados	Instituição	Registros
TIC Domicílios 2025	CETIC.br / CGI.br	27.177 domicílios (25.233 após limpeza)
Reuters Digital News Report 2025	Reuters Institute / Oxford	Dados agregados do Brasil

Fonte: Elaborado pelas autoras (2026).

Observa-se que a pesquisa utilizou bases de dados de relevância nacional e internacional, permitindo integrar informações relacionadas à infraestrutura tecnológica doméstica e ao comportamento de consumo de notícias em plataformas digitais. A combinação dessas fontes ampliou a capacidade analítica do estudo ao relacionar aspectos de conectividade, perfil socioeconômico e hábitos informacionais da população brasileira. Após o tratamento e o pré-processamento dos dados, a base final utilizada na modelagem contou com 25.233 registros válidos.

5.2 Pré-processamento dos dados

A etapa de preparação dos dados envolveu limpeza da base, tratamento de inconsistências e análise de valores ausentes. Nos testes iniciais, verificou-se que a exclusão

automática de registros incompletos reduzia significativamente a amostra, comprometendo a representatividade dos dados, especialmente em questões condicionais relacionadas ao acesso à internet e uso de plataformas digitais.

Para evitar distorções estatísticas, adotou-se um tratamento controlado dos dados ausentes, preservando registros representativos da população desconectada. As variáveis categóricas foram convertidas em formato numérico binário por meio da técnica One-Hot Encoding, permitindo o processamento adequado pelos algoritmos de agrupamento. Entre as principais variáveis utilizadas no modelo destacam-se presença de televisão e rádio, acesso à internet, uso de celular para conexão, escolaridade, faixa de renda, localização urbana ou rural e utilização de plataformas como YouTube, Instagram, WhatsApp e Facebook para acesso a notícias.

5.3 Modelagem dos dados

Após a preparação da base, iniciou-se a etapa de modelagem utilizando algoritmos de aprendizado não supervisionado. O principal algoritmo aplicado foi o K-Means, utilizado para identificar agrupamentos de comportamento entre os domicílios brasileiros. A definição do número ideal de clusters foi realizada por meio do Método do Cotovelo (Elbow Method), indicando $K = 4$ como valor mais adequado, devido à estabilização da redução da variabilidade interna a partir desse ponto.

A qualidade dos agrupamentos foi avaliada pelo Silhouette Score, enquanto o método Hierárquico Ward foi utilizado como técnica complementar de validação estrutural dos clusters encontrados. A base original continha 27.177 registros, dos quais 25.233 foram mantidos após as etapas de limpeza e pré-processamento. O Quadro 2 sintetiza o escopo metodológico adotado na etapa de modelagem.

Quadro 2 – Estrutura geral da abordagem de clustering

Métrica	Resultado
Número de registros	25.233 registros válidos
Número de clusters	4
Método de validação	Silhouette Score
Técnica complementar	Ward Hierárquico

Fonte: Elaborado pelas autoras (2026).

Os critérios de desenho amostral e os parâmetros apresentados no Quadro 2 contribuíram para garantir a estabilidade da segmentação em uma base sociodemográfica de grande porte. A definição de quatro clusters mostrou-se adequada para representar diferentes padrões de consumo de mídia e conectividade digital no Brasil. Segundo Han, Kamber e Pei (2011), a combinação de diferentes técnicas de clustering aumenta a robustez analítica e reduz o risco de segmentações artificiais em bases complexas. O Quadro 3 apresenta os principais parâmetros utilizados na configuração dos algoritmos aplicados na modelagem.

Quadro 3 – Parâmetros e métricas dos algoritmos utilizados

Algoritmo	Parâmetro	Valor	Justificativa
K-Means	Número de Clusters (K)	4	Método do Cotovelo — inflexão em k=4
K-Means	n_init	10	Múltiplas inicializações para evitar redução do risco de mínimos locais
K-Means	Silhouette Score	0,294	Avaliação da qualidade dos clusters
Hierárquico Ward	Número de clusters	4	Confirmado pelo dendrograma
Hierárquico Ward	Silhouette Score	0,285	Validação comparativa
Apriori	Suporte mínimo	10%	Frequência mínima nos domicílios
Apriori	Confiança mínima	60%	Probabilidade mínima da regra

Algoritmo	Parâmetro	Valor	Justificativa
Apriori	Lift mínimo	> 1,2	Associação acima do esperado aleatoriamente

Fonte: Elaborado pelas autoras (2026).

Os parâmetros apresentados foram definidos a partir de testes exploratórios e critérios estatísticos amplamente utilizados em mineração de dados. A definição de quatro clusters mostrou-se coerente tanto pelo Método do Cotovelo quanto pela análise do dendrograma hierárquico. Os valores de Silhouette Score obtidos pelos algoritmos K-Means e Hierárquico Ward foram considerados satisfatórios para uma base social complexa, caracterizada por comportamentos heterogêneos e zonas de sobreposição entre perfis populacionais.

No caso do algoritmo Apriori, os limiares mínimos de suporte, confiança e lift foram definidos com o objetivo de selecionar apenas associações estatisticamente relevantes e com maior potencial interpretativo. Na sequência, aplicou-se o algoritmo Apriori para mineração de regras de associação, buscando identificar padrões frequentes entre consumo de mídia, infraestrutura tecnológica e perfil socioeconômico.

5.4 Ferramentas utilizadas

As análises foram desenvolvidas em Python, com apoio das bibliotecas: Pandas, Scikit-Learn, Mlxtend, Matplotlib e Seaborn. O processamento incluiu técnicas de pré-processamento, transformação categórica por One-Hot Encoding e avaliação de agrupamentos por métricas de inércia e Silhouette Score.

6. DESENVOLVIMENTO E RESULTADOS


6.1 P1 – Infraestrutura de mídia nos domicílios brasileiros

A análise da infraestrutura tecnológica dos domicílios brasileiros constitui um dos eixos centrais deste estudo, pois permite compreender as condições materiais que viabilizam o acesso à informação e ao consumo de mídia digital. Com base nos microdados da pesquisa TIC Domicílios 2025, foram investigados os principais dispositivos de comunicação presentes nos lares brasileiros, abrangendo tanto tecnologias tradicionais quanto digitais.

A primeira etapa da análise concentrou-se na identificação da infraestrutura tecnológica presente nos domicílios brasileiros. Os resultados revelam um cenário de coexistência entre meios tradicionais e digitais, evidenciando que o processo de transformação midiática no Brasil ocorre de maneira híbrida, e não substitutiva.

A televisão permanece como o dispositivo de mídia com maior presença nos lares analisados, demonstrando elevada capilaridade nacional mesmo diante do crescimento das plataformas digitais. O acesso à internet também apresenta índices expressivos, indicando a consolidação progressiva da conectividade digital no país. O rádio, por sua vez, apresenta presença significativamente menor em comparação à televisão e à internet, sugerindo uma redução gradual de sua centralidade histórica no consumo cotidiano de informação. A distribuição dessas tecnologias de acesso pode ser observada detalhadamente na Figura 1.

Figura 1 – P1 — Infraestrutura: penetração de aparelhos (TIC Domicílios 2025)



Fonte: Elaborado pelas autoras (2026)

A Figura 1 evidencia a consolidação da internet como principal meio de conectividade nos domicílios brasileiros, com presença em 80,2% dos lares analisados. Observa-se também a forte penetração do acesso móvel à internet por meio de celulares (71,3%), indicando a centralidade dos dispositivos móveis no ecossistema digital contemporâneo. Em contrapartida, a televisão ainda apresenta elevada presença (68,2%), reforçando sua permanência como meio tradicional de comunicação amplamente difundido no país. O rádio, embora historicamente

relevante, aparece com menor presença (35,4%), sugerindo um processo gradual de redução de sua centralidade informacional.

Esses resultados corroboram a perspectiva de Jenkins (2009) sobre convergência midiática, na qual diferentes meios coexistem em um ambiente híbrido, em vez de serem substituídos integralmente. Além disso, os dados reforçam a análise de Castells (2009) sobre a sociedade em rede, caracterizada pela crescente centralidade da conectividade digital na organização das relações sociais contemporâneas.

Entretanto, os resultados também revelam permanência de desigualdades estruturais importantes. Embora a conectividade digital tenha avançado significativamente, parte dos domicílios ainda permanece distante do ambiente online, evidenciando limitações relacionadas à infraestrutura tecnológica e às condições socioeconômicas.

Essa desigualdade reforça a discussão proposta por Tanenbaum (2003) e Kurose (2010) sobre a dependência da infraestrutura de redes para integração plena na sociedade digital. O acesso à informação contemporânea está diretamente condicionado à disponibilidade de conectividade e dispositivos tecnológicos.

6.2 P2 – Hábitos de informação e consumo digital


A segunda etapa da análise buscou identificar quais plataformas concentram o consumo de notícias entre os domicílios conectados. Os resultados mostraram forte presença de plataformas digitais como YouTube, Instagram e WhatsApp no acesso cotidiano à informação. O YouTube destacou-se como uma das principais fontes de consumo de conteúdo informacional, especialmente entre usuários altamente conectados.

O Instagram também apresentou elevada utilização para acompanhamento de notícias, enquanto o WhatsApp demonstrou papel central na circulação e compartilhamento de conteúdos informacionais. Após a caracterização da infraestrutura de acesso à informação nos domicílios brasileiros, a etapa seguinte da metodologia CRISP-DM consiste em compreender como esses recursos são efetivamente utilizados no consumo de notícias. Esse movimento permite relacionar disponibilidade tecnológica e práticas informacionais da população.

Nesse contexto, observa-se a intensificação da migração do consumo de mídia para ambientes digitais, ao mesmo tempo em que veículos tradicionais ainda mantêm relevância em determinados segmentos da audiência. Para essa análise, foram utilizados dados consolidados

do *Reuters Digital News Report 2025*, referentes ao Brasil. O conjunto de indicadores apresenta o percentual da população que utiliza diferentes meios e plataformas de informação ao menos uma vez por semana para consumo de notícias. A distribuição dessas preferências pode ser observada na Figura 2.

Figura 2 - P2 — Hábitos de informação: por onde as pessoas se informam (TIC Domicílios 2025)



Fonte: Elaborado pelas autoras (2026)

A Figura 2 evidencia a centralidade da televisão como principal meio de informação no Brasil, utilizada semanalmente por 78,0% da população. Apesar da expansão das plataformas digitais, o resultado demonstra que a televisão ainda mantém forte relevância no consumo de notícias. Em seguida, destacam-se os portais e sites de notícias, utilizados por 50,0% dos respondentes, consolidando-se como importante canal digital de informação.

Entre as plataformas digitais, observa-se distribuição semelhante entre Instagram (37,0%), YouTube (37,0%) e WhatsApp (36,0%), indicando diversificação dos canais de acesso e fortalecimento de formatos audiovisuais e comunicacionais baseados em redes sociais. Em contrapartida, o jornal impresso apresenta menor participação (14,0%), reforçando a redução do consumo de mídia física. O rádio mantém presença intermediária (28,0%), enquanto TikTok

(18,0%), podcasts (10,0%), chatbots de inteligência artificial (9,0%) e X/Twitter (9,0%) aparecem como meios complementares ou emergentes no ecossistema informacional.

De modo geral, os dados revelam um cenário híbrido de consumo midiático, marcado pela coexistência entre meios tradicionais e digitais, além da crescente fragmentação das fontes de informação. Segundo Santaella (2003), a cibercultura transformou o consumo comunicacional em uma experiência baseada na mobilidade, instantaneidade e fragmentação dos conteúdos. O destaque do YouTube e do Instagram reforça essa dinâmica, caracterizada pela predominância de conteúdos audiovisuais rápidos e altamente compartilháveis.


O WhatsApp, por sua vez, apresenta relevância particular no contexto brasileiro por operar majoritariamente em ambientes privados de circulação de mensagens, dificultando processos tradicionais de mediação e verificação da informação. Castells (2009) descreve esse fenômeno como comunicação de massa autoprogramada, em que indivíduos passam a produzir e compartilhar conteúdos sem depender diretamente dos grandes veículos tradicionais. Ao mesmo tempo, Lévy (1999) destaca que o ciberespaço amplia possibilidades de inteligência coletiva e compartilhamento da informação, embora também favoreça a circulação acelerada de conteúdos desinformativos.

6.3 P3 – Confiança nas notícias e descentralização da informação

Embora a base analisada não possua uma variável específica sobre confiança nas notícias, os padrões de consumo identificados permitem discutir transformações relevantes na relação da população com as fontes de informação. Os resultados indicaram crescimento do consumo de notícias por plataformas digitais descentralizadas, especialmente redes sociais e aplicativos de mensagens.

Nesta etapa, busca-se analisar a relação entre confiança nos meios de comunicação e percepção de desinformação no ambiente digital. Para isso, foram utilizados indicadores do Digital News Report 2025, permitindo observar diferentes níveis de confiança e preocupação com fake news nas plataformas analisadas, conforme apresentado na Figura 3.

Figura 3 – P3 — Confiança: credibilidade por meio da informação (TIC Domicílios 2025)



Fonte: Elaborado pelas autoras (2026)

O mapeamento apresentado na Figura 3 evidencia um cenário de divisão nas percepções de confiança informacional no Brasil. Na seção referente à confiança nos veículos tradicionais, observa-se que rádio (59,0%), televisão (55,0%) e jornal impresso (54,0%) concentram os maiores índices de credibilidade, indicando que os meios tradicionais ainda desempenham papel relevante na validação das informações. Os portais e sites de notícias aparecem em seguida, com 51,0% de confiança.

Em contraste, a seção relacionada à preocupação com fake news nas plataformas digitais revela elevados níveis de desconfiança nos ambientes online. Os portais e sites de notícias lideram esse indicador, com 60,0% de preocupação, seguidos por YouTube (54,0%), Facebook (51,0%) e WhatsApp (51,0%). O Instagram apresenta 49,0%, enquanto TikTok (44,0%) e X/Twitter (41,0%) registram menores índices de preocupação, possivelmente associados ao uso mais voltado ao entretenimento e à interação informal.

Os resultados evidenciam um cenário marcado pela coexistência entre uso intensivo das plataformas digitais e percepção de vulnerabilidade à desinformação, configurando o chamado “paradoxo da confiança digital”. Embora as redes sociais e aplicativos sejam amplamente utilizados pela praticidade e velocidade de acesso, os usuários reconhecem limitações relacionadas à credibilidade das informações circulantes.

Segundo Jenkins (2009), a convergência midiática favorece a circulação simultânea entre diferentes meios de comunicação, enquanto Castells (2009) argumenta que as redes digitais reorganizam as relações de poder informacional ao descentralizar a produção e

distribuição de conteúdos. No contexto brasileiro, o WhatsApp assume papel particularmente relevante devido à circulação privada de mensagens, reduzindo mecanismos tradicionais de mediação e verificação jornalística.


Santaella (2003) destaca que a cibercultura promove ambientes informacionais fragmentados e personalizados, influenciados por recomendações algorítmicas e interesses individuais. Esse processo contribui para a formação de bolhas informacionais e altera significativamente a dinâmica contemporânea do consumo de notícias.

6.4 P4 – Desigualdade digital e exclusão informacional

A análise dos dados revelou forte relação entre renda, escolaridade e acesso às plataformas digitais. Domicílios com maior nível educacional e melhor infraestrutura tecnológica apresentaram maior diversidade de consumo midiático e uso simultâneo de plataformas digitais. Em contrapartida, grupos socialmente mais vulneráveis demonstraram maior dependência dos meios tradicionais de comunicação.

Nesta etapa da análise exploratória, busca-se compreender como fatores socioeconômicos influenciam a divisão digital no Brasil. Embora o consumo de mídia digital tenha crescido significativamente, os dados indicam que o acesso à conectividade ainda ocorre de forma desigual entre diferentes grupos sociais. Com base nos microdados da pesquisa TIC Domicílios 2025, foram relacionadas informações sobre acesso à internet, faixa de renda e escolaridade do responsável pelo domicílio. Os resultados apresentados na Figura 4 evidenciam como as desigualdades sociais ainda impactam diretamente o acesso à conectividade e ao consumo digital no país.

Figura 4 — P4: Desigualdade social no acesso digital (TIC Domicílios 2025)



Fonte: Elaborado pelas autoras (2026)

Os dados apresentados na Figura 4 demonstram que o acesso à internet no Brasil ainda varia significativamente conforme renda e escolaridade. No painel referente à faixa de renda, observa-se crescimento progressivo da conectividade à medida que aumenta o poder aquisitivo dos domicílios. Entre as famílias de menor renda (até R\$ 100), o acesso à internet é de 69,9%, enquanto nas faixas superiores os índices ultrapassam 95%. O grupo de renda não declarada apresenta o menor percentual de acesso (59,2%), sugerindo associação com situações de vulnerabilidade socioeconômica e informalidade.

No painel relacionado à escolaridade, a desigualdade torna-se ainda mais evidente. Entre responsáveis sem instrução formal, apenas 51,5% possuem acesso à internet. O percentual aumenta gradualmente conforme o nível educacional, alcançando 72,1% no ensino fundamental, 86,5% no ensino médio e 96,3% entre indivíduos com pós-graduação. Os resultados indicam que a exclusão digital no Brasil está diretamente associada às desigualdades econômicas e educacionais. Mais do que uma questão de infraestrutura, o acesso à conectividade reflete condições sociais estruturais, reforçando diferenças no acesso à informação e à participação digital.


Segundo Castells (2009), a integração às redes digitais tornou-se elemento central para participação econômica, cultural e política na sociedade contemporânea. Da mesma forma, Lévy (1999) argumenta que o potencial da inteligência coletiva depende da ampliação do acesso às tecnologias e ao ambiente digital. Nesse contexto, os resultados evidenciam que a inclusão digital envolve não apenas infraestrutura técnica, mas também fatores relacionados à renda, escolaridade e capacidade de utilização das plataformas digitais.

6.5 Formação dos clusters e segmentação comportamental

A aplicação do algoritmo K-Means permitiu identificar quatro agrupamentos principais de comportamento relacionados ao consumo de mídia no Brasil. A segmentação revelou diferenças relevantes entre níveis de conectividade, utilização de plataformas digitais e permanência de hábitos tradicionais de informação. A definição do número ideal de clusters foi realizada utilizando o Método do Cotovelo, que analisa a redução da variabilidade interna dos grupos conforme o aumento do número de agrupamentos.

Para determinar o número ideal de clusters na aplicação do algoritmo K-Means, utiliza-se o Método do Cotovelo, uma técnica amplamente empregada para identificar o ponto em que o ganho de explicação da variância começa a diminuir de forma significativa. Esse método permite avaliar a relação entre o número de clusters e a inércia do modelo, auxiliando na escolha de uma configuração mais equilibrada e interpretável. A análise foi aplicada aos dados da pesquisa TIC Domicílios 2025, variando-se o número de clusters (k) para observar o comportamento da inércia ao longo das iterações. O resultado é apresentado na Figura 5.

Figura 5 – Método do Cotovelo (Elbow Method) - (TIC Domicílios 2025)




Fonte: Elaborado pelas autoras (2026)

A Figura 5 apresenta a curva do Método do Cotovelo, evidenciando a redução progressiva da inércia conforme aumenta o número de clusters. Observa-se queda mais acentuada entre $k = 2$ e $k = 4$, seguida por estabilização da curva a partir desse ponto, indicando que os ganhos na explicação da variabilidade passam a ser menos significativos após quatro agrupamentos.

Os resultados sugerem que $K = 4$ representa o melhor equilíbrio entre capacidade de segmentação e simplicidade do modelo, evitando tanto a subsegmentação quanto o excesso de fragmentação dos dados. Segundo Han, Kamber e Pei (2011), o algoritmo K-Means busca minimizar a distância interna entre os elementos de cada grupo, formando clusters compostos por registros com características semelhantes. Além disso, o Silhouette Score apresentou resultado satisfatório para dados sociais complexos, indicando separação adequada entre os agrupamentos encontrados. Como técnica complementar de validação estrutural, também foi aplicado o Clustering Hierárquico Ward.

Para verificar a estabilidade dos grupos formados pelo K-Means, o método hierárquico foi executado em uma amostra de 500 registros da base TIC Domicílios 2025. O modelo de Ward opera de forma aglomerativa, iniciando com cada domicílio isolado e realizando sucessivas uniões entre os registros mais semelhantes até a formação de um único agrupamento. O resultado desse processo é apresentado na Figura 6, permitindo observar as relações de proximidade entre os perfis identificados.

Figura 6 — Validação dos perfis via agrupamento hierárquico (Ward) - Dendrograma (TIC Domicílios 2025)



Fonte: Elaborado pelas autoras (2026)

A leitura do dendrograma apresentado na Figura 6 reforça a consistência do modelo proposto. Nesse tipo de gráfico, o eixo vertical representa a distância entre os grupos: quanto maior a altura da união entre dois ramos, maior é a diferença entre eles. A linha horizontal tracejada em vermelho indica o corte sugerido para $k = 4$, posicionada em uma distância aproximada de 25. Ao aplicar esse corte, o gráfico é dividido exatamente em quatro grandes ramos.

Os quatro ramos identificados no dendrograma correspondem diretamente à segmentação obtida pelo algoritmo K-Means. Os dois ramos à esquerda representam grupos mais distintos entre si, com perfis bem definidos, enquanto os dois ramos à direita apresentam subdivisões mais próximas, indicando perfis que compartilham características digitais, mas diferem em aspectos como renda e escolaridade.

O fato de o método hierárquico também indicar a formação de quatro grupos reforça a consistência da estrutura encontrada, sugerindo naturalmente a existência dos perfis Tradicional Puro, Digital Urbano, Digital Rural e Digital Premium. O dendrograma apresentou formação relativamente estável entre os agrupamentos, confirmando a robustez dos resultados obtidos pelo K-Means.

Segundo Everitt et al. (2011), métodos hierárquicos permitem analisar relações de proximidade entre registros e avaliar visualmente a estrutura dos agrupamentos formados. A partir dessa validação, a próxima etapa apresenta a matriz de concordância entre os dois modelos, permitindo medir o nível de equivalência entre as classificações.

O Quadro 4 apresenta os índices médios de cada indicador por cluster, permitindo identificar o comportamento predominante em cada perfil:

Quadro 4 – Características médias dos clusters identificados

Cluster	Perfil	Participação (%)	Acesso à internet	Índice médio de renda	escolaridade	Área predominante
0	Digital Urbano	13.413 (53,2%)	1,00	2,17	3,14	1,00
1	Tradicional Puro	4.987 (19,8%)	0,01	1,69	2,18	1,28

Cluster	Perfil	Participação (%)	Acesso à internet	Índice médio de renda	escolaridade	Área predominante
2	Digital Rural	3.609 (14,3%)	0,99	1,84	2,59	2,00
3	Digital Premium	3.224 (12,8%)	0,99	3,03	3,62	1,11

Fonte: Elaborado pelas autoras (2026).

Os dados apresentados no Quadro 4 mostram que o acesso à internet no Brasil ainda não é totalmente universal e varia fortemente conforme renda e escolaridade. A leitura destaca alguns padrões relevantes na segmentação dos clusters. O Cluster Digital Urbano é o grupo predominante, representando 53,2% da amostra. Esse segmento apresenta elevada conectividade e forte inserção em plataformas digitais, indicando ampla integração ao ecossistema informacional contemporâneo.

Em contraste, o Cluster Tradicional Puro (19,8%) concentra os menores níveis de acesso à internet, além de indicadores reduzidos de renda e escolaridade. Esse padrão reforça a associação entre exclusão digital e desigualdade socioeconômica observada na pesquisa. O Cluster Digital Rural (14,3%) evidencia um fenômeno relevante de inclusão digital no meio rural, com alto nível de acesso à internet (0,99), indicando que a conectividade ultrapassa barreiras territoriais, embora ainda coexistam diferenças estruturais. Por fim, o Cluster Digital Premium (12,8%), apesar de ser o menor grupo, apresenta os maiores índices de renda e escolaridade, caracterizando um público de alto valor socioeconômico e elevada capacidade de consumo informacional.

Os resultados indicam que a transformação digital no Brasil ocorre de forma heterogênea, com diferentes níveis de integração tecnológica associados a fatores territoriais e socioeconômicos. Os índices médios de renda e escolaridade representam variáveis normalizadas obtidas no pré-processamento da base, sendo interpretados de forma relativa entre os clusters. A partir da matriz consolidada das características médias, destaca-se o Quadro 5, que sintetiza qualitativamente os perfis comportamentais mapeados.

Quadro 5 – Síntese dos perfis de clusters identificados

Cluster	Perfil	Características principais
0	Digital Urbano	Alta conectividade e forte uso de redes sociais
1	Tradicional Puro	Baixa conectividade e predominância de TV
2	Digital Premium	Alto consumo audiovisual digital
3	Digital Rural	Conectividade intermediária

Fonte: Elaborado pelas autoras (2026)


6.5.1 Cluster 0 – Digital Urbano

O cluster Digital Urbano representa domicílios altamente conectados e fortemente inseridos no ecossistema digital. Os resultados demonstraram elevada presença de internet, intensa utilização de Instagram e WhatsApp e coexistência entre televisão e plataformas digitais. Esse comportamento reforça o conceito de convergência midiática discutido por Jenkins (2009), no qual diferentes meios de comunicação coexistem no consumo cotidiano de informação.

A forte utilização de plataformas digitais também dialoga com a lógica da hiperconectividade descrita por Santaella (2003), marcada pela circulação rápida de conteúdos em ambientes móveis e permanentemente conectados. Além disso, o uso intenso do WhatsApp evidencia a presença da comunicação de massa autoprogramada proposta por Castells (2009), em que indivíduos deixam de atuar apenas como receptores e passam também a compartilhar conteúdos em redes digitais descentralizadas.

Para visualizar a distribuição dos perfis identificados pelo K-Means, foi utilizada a técnica PCA (Análise de Componentes Principais), responsável por reduzir a dimensionalidade dos dados e projetar os registros em um plano bidimensional. O resultado apresentado na Figura 7 permite observar a distribuição dos diferentes perfis de consumo midiático no espaço analítico.

Figura 7 – Visualização espacial dos perfis de audiência (TIC Domicílios 2025)



Fonte: Elaborado pelas autoras (2026)

A Figura 7 apresenta a distribuição espacial dos quatro perfis identificados pelo algoritmo K-Means. Cada ponto representa um domicílio, enquanto as cores indicam os clusters formados. De modo geral, observa-se separação consistente entre os grupos, embora existam áreas de proximidade entre alguns perfis. No eixo horizontal (Componente Principal 1), percebe-se relação com o nível de inclusão digital e acesso à tecnologia. À esquerda do gráfico concentra-se o cluster Digital Urbano (53,2%), caracterizado por elevada conectividade e forte presença de plataformas digitais no cotidiano.

Na região central e inferior aparecem os clusters Digital Rural (14,3%) e Tradicional Puro (19,8%), que compartilham algumas características socioeconômicas semelhantes. Apesar dessa proximidade, o modelo conseguiu diferenciá-los, principalmente pelo maior nível de conectividade observado no grupo Digital Rural em comparação ao perfil Tradicional Puro, mais dependente de televisão e rádio. No canto superior direito destaca-se o cluster Digital Premium (12,8%), mais distante dos demais agrupamentos. Essa separação sugere um perfil associado a maiores níveis de renda, escolaridade e diversidade de consumo digital.

De forma geral, a visualização confirma a capacidade do K-Means em identificar grupos relativamente bem definidos e interpretáveis. Para complementar a análise dos padrões encontrados, a próxima etapa apresenta as regras de associação geradas pelo algoritmo Apriori.

6.5.2 Cluster 1 – Tradicional Puro

O cluster Tradicional Puro concentrou domicílios com baixa conectividade digital e maior dependência de meios tradicionais, como televisão e rádio. A reduzida presença de internet e plataformas digitais sugere um perfil associado à exclusão digital e menor integração às dinâmicas da sociedade em rede. Segundo Castells (2009), a ausência de conectividade limita a participação social, econômica e informacional dos indivíduos na sociedade contemporânea. Os resultados também indicam relação entre baixa conectividade, menor escolaridade e restrições socioeconômicas, evidenciando que a exclusão digital permanece associada às desigualdades estruturais brasileiras. Sob a perspectiva de Bourdieu (1983), esse comportamento pode ser interpretado como reflexo das desigualdades de capital cultural, nas quais o acesso limitado às tecnologias digitais reduz oportunidades de inserção em ambientes informacionais mais diversificados.

6.5.3 Cluster 2 – Digital Premium

O cluster Digital Premium apresentou os maiores níveis de conectividade e forte predominância de consumo digital audiovisual. O YouTube destacou-se nesse agrupamento, acompanhado de elevada presença de internet e utilização simultânea de múltiplas plataformas digitais. Os resultados indicaram associação entre TV por assinatura, alta escolaridade e conectividade digital, evidenciando um perfil fortemente integrado ao ambiente digital contemporâneo. Segundo Santaella (2003), esse comportamento caracteriza a lógica da cibercultura, marcada pela circulação contínua de conteúdos multimídia e hiperconectividade.

O protagonismo do YouTube demonstra a crescente centralidade da comunicação audiovisual no consumo de informação, enquanto a intensa utilização de plataformas digitais sugere forte influência de sistemas algorítmicos de recomendação. Segundo Bauman (2001), a modernidade contemporânea é marcada por fluxos rápidos e consumo acelerado de informação, comportamento perceptível nesse perfil de usuários.

6.5.4 Cluster 3 – Digital Rural

O cluster Digital Rural apresentou características intermediárias entre inclusão digital e permanência de hábitos tradicionais de consumo de mídia. Embora exista presença relevante de internet, o padrão de utilização digital mostrou-se menos intenso em comparação aos clusters urbanos e premium. Os resultados sugerem que a expansão da conectividade alcançou parte dos domicílios localizados fora dos grandes centros urbanos, embora ainda persistam limitações relacionadas à infraestrutura tecnológica e à diversidade de acesso digital.

Segundo Castells (2009), a integração desigual às redes digitais produz diferentes níveis de participação na sociedade em rede, ampliando assimetrias de acesso à informação e oportunidades comunicacionais. Além disso, a permanência parcial de hábitos tradicionais de mídia reforça que a transformação digital brasileira ocorre de forma heterogênea e gradual, especialmente em contextos social e geograficamente mais vulneráveis.


6.6 Regras de associação e padrões comportamentais

A aplicação do algoritmo Apriori permitiu identificar relações frequentes entre infraestrutura tecnológica, perfil socioeconômico e hábitos de consumo de mídia. Foram encontradas associações relevantes entre: acesso à internet, uso de smartphones, consumo de YouTube, escolaridade elevada e utilização simultânea de múltiplas plataformas digitais.

Após a mineração das 335 regras de associação pelo algoritmo Apriori, é necessário um recurso visual que facilite a interpretação dos padrões encontrados. Para isso, foi construído um mapa de calor (heatmap) com base na métrica Lift. O Lift funciona como uma medida de força da relação entre duas variáveis: valores próximos de 1 indicam independência entre os eventos, enquanto valores acima de 1 mostram associação positiva, ou seja, a ocorrência de um elemento aumenta a probabilidade do outro.

A Figura 8 apresenta esse mapeamento, com os antecedentes nas linhas e os consequentes nas colunas, permitindo identificar rapidamente as relações mais relevantes entre características sociais e padrões de consumo de mídia nos domicílios brasileiros.

Figura 8 – Análise visual das regras por meio do mapa de calor



Fonte: Elaborado pelas autoras (2026)

A Figura 8 apresenta, em diferentes intensidades de azul, a força das relações entre características socioeconômicas e padrões de consumo de mídia nos domicílios brasileiros. Tons mais escuros indicam associações mais fortes (maior Lift), enquanto valores iguais a 0,00 representam regras que não atingiram os critérios mínimos de relevância estatística.

Os resultados evidenciaram forte associação entre conectividade digital, escolaridade e diversidade de consumo midiático. A variável TV_Assinatura apresentou os maiores valores de Lift, especialmente em combinações envolvendo Internet, Alta_Escol e uso de celular com conexão móvel, perfil característico do grupo Digital Premium. Também foram identificadas associações consistentes entre alta renda, contexto urbano e maior conectividade digital, indicando que renda, escolaridade e acesso à internet tendem a ocorrer de forma conjunta. Esses padrões reforçam a relação entre inclusão digital e condições socioeconômicas mais favoráveis.

Enquanto os algoritmos de clustering permitiram identificar os principais perfis de audiência, o algoritmo Apriori possibilitou compreender como diferentes hábitos de mídia e conectividade ocorrem simultaneamente nos domicílios brasileiros. O modelo foi configurado com suporte mínimo de 10%, confiança mínima de 60% e Lift superior a 1,2, garantindo a seleção de associações estatisticamente relevantes. Ao todo, foram geradas 335 regras de associação, das quais as mais representativas são apresentadas no Quadro 6.

Quadro 6 - Principais regras de associação identificadas

Regra	Suporte	Confiança	Lift
Internet → YouTube	0,42	0,81	1,53
Escolaridade Alta → Instagram	0,35	0,74	1,41
Smartphone → WhatsApp	0,67	0,89	1,22

Fonte: Elaborada pelas autoras (2026).

A análise das métricas apresentadas no Quadro 6 revelou padrões relevantes de associação entre hábitos digitais e características dos domicílios brasileiros. A primeira regra demonstrou forte relação entre presença de internet e consumo de conteúdo no YouTube, com suporte de 0,42, confiança de 0,81 e Lift de 1,53, indicando elevada probabilidade de utilização da plataforma em domicílios conectados.

A segunda regra evidenciou associação entre alta escolaridade e uso do Instagram, apresentando suporte de 0,35, confiança de 0,74 e Lift de 1,41. Os resultados sugerem que maiores níveis educacionais estão relacionados ao uso mais intenso de redes sociais visuais e informacionais. Já a terceira regra destacou a relação entre smartphone e utilização do WhatsApp, sendo a associação mais frequente observada no modelo, com suporte de 0,67 e confiança de 0,89. Esse comportamento reforça a centralidade dos dispositivos móveis e aplicativos de mensagens na experiência digital contemporânea.

De forma geral, os resultados indicam que internet e smartphone funcionam como elementos centrais da conectividade digital, integrando os usuários a plataformas de vídeo, redes sociais e aplicativos de comunicação. O Quadro 7 apresenta as principais regras de associação identificadas pelo algoritmo Apriori, aprofundando a relação entre conectividade, perfil socioeconômico e consumo de mídia.

Quadro 7 – Principais regras de associação identificadas pelo algoritmo Apriori

Antecedente (A)	Consequente (B)	Suporte	Confiança	Lift	Interpretação
TV_Assinatura	TV, Alta_Escol	10,1%	77,1%	1,55	TV paga é forte indicador de alta escolaridade
TV_Assinatura	Alta_Escol, Internet	10,1%	77,1%	1,55	TV paga + internet = perfil premium
Alta_Renda	Celular_Net, Alta_Escol	17,9%	66,8%	1,46	Alta renda combina celular e educação
TV_Assin, Internet	Alta_Escol	10,1%	79,1%	1,44	TV paga + internet → alta escolaridade
TV_Assinatura	Celular_Net, Urbano	11,0%	83,6%	1,44	Assinantes de TV são urbanos e digitais
TV_Assinatura	TV, Celular_Net	12,3%	93,7%	1,41	97% dos que têm TV paga usam celular

Fonte: Elaborada pelas autoras (2026).

As regras de associação identificadas no Quadro 7 evidenciam relações consistentes entre renda, escolaridade e conectividade digital. Os maiores valores de lift concentram-se em padrões que envolvem televisão por assinatura, acesso móvel à internet e níveis elevados de escolaridade, indicando que o consumo digital mais diversificado está associado a grupos socialmente mais favorecidos.

Os resultados também apontam para a coexistência entre meios tradicionais e digitais, especialmente na associação entre televisão por assinatura e uso de dispositivos móveis conectados. Esse padrão reforça a lógica de convergência midiática discutida por Jenkins (2009), na qual diferentes plataformas operam de forma integrada no cotidiano dos usuários. Além disso, observa-se que o acesso móvel à internet está fortemente relacionado ao consumo de plataformas audiovisuais digitais, o que se alinha ao conceito de comunicação ubíqua de Santaella (2003), caracterizada pela circulação contínua da informação em dispositivos conectados.

Em conjunto, os achados indicam que a inclusão digital não depende apenas da infraestrutura tecnológica, mas também de fatores socioeconômicos e culturais. Essa interpretação dialoga com Bourdieu (1983), ao evidenciar o papel do capital cultural na


configuração dos padrões de consumo informacional, e com Castells (2009), ao reforçar que a sociedade em rede permanece marcada por assimetrias no acesso e no uso das tecnologias digitais.

6.7 Comparação entre K-Means e Clustering Hierárquico Ward

A utilização conjunta do K-Means e do Clustering Hierárquico Ward permitiu validar a consistência dos agrupamentos encontrados. Enquanto o K-Means apresentou maior eficiência computacional para segmentação da base, o método hierárquico possibilitou observar visualmente as relações de proximidade entre os grupos. Os resultados demonstraram relativa convergência entre os métodos, indicando estabilidade estrutural dos clusters identificados.

Com o objetivo de validar a consistência dos agrupamentos encontrados, realizou-se comparação entre os resultados obtidos pelo algoritmo K-Means e pelo método Hierárquico Ward. Para facilitar a visualização dos clusters, os dados foram projetados em dois componentes principais por meio da técnica PCA (Principal Component Analysis). A comparação pode ser analisada na Figura 9.

Figura 9 – Comparação entre os agrupamentos gerados pelo K-Means e Clustering Hierárquico Ward



Fonte: Elaborado pelas autoras (2026).

A Figura 9 demonstra que os algoritmos K-Means e Hierárquico Ward apresentaram estruturas de agrupamento relativamente semelhantes, indicando estabilidade dos perfis identificados na base de dados. O K-Means obteve Silhouette Score de 0,294, enquanto o método Ward apresentou 0,285. Embora os valores sejam moderados, esse comportamento é

esperado em bases sociais complexas, nas quais os perfis raramente apresentam separações completamente definidas.

Observa-se a existência de regiões de sobreposição parcial entre alguns grupos, especialmente nos perfis digitais intermediários. Ainda assim, os algoritmos conseguiram identificar padrões relevantes relacionados à conectividade, escolaridade e consumo de mídia. Segundo Everitt et al. (2011), diferentes técnicas de clustering podem gerar segmentações parcialmente distintas devido aos métodos específicos de cálculo de similaridade utilizados por cada algoritmo. Nesse contexto, a convergência observada entre os modelos reforça a confiabilidade dos agrupamentos encontrados.

Para ampliar a robustez da análise, foi realizada validação cruzada entre o K-Means, baseado em particionamento por centroides, e o método Hierárquico Ward, construído por agrupamento progressivo das distâncias entre os registros. O Quadro 8 apresenta a comparação entre os modelos considerando desempenho, estabilidade dos clusters e interpretabilidade dos resultados.

Quadro 8 - Comparação estrutural: K-Means vs. clustering hierárquico (Ward)

Critério	K-Means	Hierárquico Ward
Silhouette Score	0,294	0,285
Número de clusters	4	4 (confirmado pelo dendrograma)
Concordância entre modelos	97,9%	97,9%
Tempo de execução	Rápido	Mais lento na base completa
Interpretabilidade	Alta	Alta (com dendrograma)

Fonte: Elaboração das autoras (2026)


No critério de qualidade dos agrupamentos, medido pelo Silhouette Score, o K-Means apresentou leve vantagem em relação ao método Hierárquico Ward (0,294 contra 0,285), conforme mostrado no Quadro 8. Apesar da diferença reduzida, ambos os valores indicam separação adequada dos grupos em uma base sociodemográfica complexa. Outro resultado relevante foi a convergência dos dois métodos para o mesmo número de clusters: quatro. Esse

comportamento reforça a estabilidade da estrutura identificada anteriormente pelo Método do Cotovelo e pelo dendrograma hierárquico.

A elevada concordância entre os modelos (97,9%) demonstra forte consistência dos agrupamentos, indicando que 24.708 dos 25.233 domicílios foram classificados no mesmo grupo pelos dois algoritmos. Esse resultado reduz a probabilidade de que os perfis encontrados sejam decorrentes de características específicas de apenas um método. Em termos computacionais, o K-Means apresentou maior eficiência de processamento, enquanto o método Hierárquico Ward demandou maior custo computacional devido ao cálculo de distâncias entre todas as observações. Ainda assim, ambos os métodos contribuíram de forma complementar para a validação dos resultados.

De forma geral, a análise conjunta reforça a robustez dos quatro perfis identificados e evidencia que a segmentação encontrada permanece consistente entre diferentes abordagens de clustering. A Figura 10 apresenta a matriz de concordância entre os agrupamentos gerados pelos dois algoritmos.

Figura 10 – Matriz de concordância entre K-Means e Clustering Hierárquico Ward



Fonte: Elaborado pelas autoras (2026)

A Figura 10 (matriz de concordância) mostra que 24.708 dos 25.233 domicílios analisados (97,9%) foram classificados no mesmo cluster pelos algoritmos K-Means e Hierárquico Ward. A pequena divergência observada (2,1%) concentrou-se principalmente nas regiões de fronteira entre os grupos, onde há maior sobreposição natural entre variáveis sociodemográficas contínuas.

A forte concentração de registros na diagonal principal da matriz evidencia elevada concordância entre os modelos, indicando estabilidade estrutural dos agrupamentos identificados. Esse resultado reforça que os quatro perfis encontrados representam padrões consistentes presentes nos dados, e não segmentações dependentes de um único algoritmo.

Segundo Everitt et al. (2011), pequenas diferenças entre métodos de clustering são esperadas devido às distintas estratégias matemáticas utilizadas no cálculo de similaridade entre os registros. Ainda assim, o elevado nível de concordância observado neste estudo demonstra robustez metodológica e confiabilidade analítica dos perfis identificados.

7. DISCUSSÃO DOS RESULTADOS

Os resultados obtidos pela mineração de dados evidenciam que o consumo de mídia no Brasil é marcado por profundas transformações estruturais, mas também por permanências históricas relacionadas às desigualdades sociais e ao acesso à tecnologia. A análise dos clusters revelou que o país vive um cenário de coexistência entre meios tradicionais e plataformas digitais, formando um ecossistema híbrido de comunicação. Embora a internet e as redes sociais tenham ampliado significativamente sua presença nos domicílios brasileiros, a televisão continua ocupando papel relevante no acesso à informação.

Esse comportamento reforça a discussão proposta por Jenkins (2009) sobre convergência midiática. Segundo o autor, novas tecnologias não substituem integralmente os meios anteriores, mas reorganizam as formas de circulação e consumo de conteúdo em ambientes multiplataforma. No caso brasileiro, os resultados demonstram que televisão, WhatsApp, YouTube e Instagram coexistem simultaneamente como fontes de informação, revelando um modelo comunicacional híbrido e descentralizado.

7.1 Plataformas digitais e fragmentação da esfera pública

O crescimento das plataformas digitais como meio principal de acesso à informação altera significativamente a dinâmica da esfera pública contemporânea. Diferentemente do modelo tradicional de comunicação de massa, baseado em fluxos centralizados de informação, as redes sociais operam sob lógica distribuída, personalizada e fortemente mediada por algoritmos.

Segundo Castells (2009), a sociedade em rede redefine as estruturas tradicionais de poder comunicacional ao permitir que indivíduos também atuem como produtores, distribuidores e replicadores de conteúdo. Os resultados encontrados neste estudo reforçam essa transformação. A elevada presença do WhatsApp e do Instagram como canais de informação demonstra que o consumo de notícias passa a ocorrer em ambientes digitais descentralizados, muitas vezes desvinculados das estruturas tradicionais de mediação jornalística.

O WhatsApp merece destaque especial nesse contexto. Sua forte presença nos clusters digitais evidencia a importância das redes privadas de compartilhamento de conteúdo no ecossistema comunicacional brasileiro. Entretanto, a circulação de informações em ambientes fechados dificulta mecanismos tradicionais de checagem, verificação e regulação editorial.

Santaella (2003) argumenta que a cibercultura produz ambientes comunicacionais altamente fragmentados, nos quais os indivíduos passam a consumir conteúdos personalizados conforme preferências específicas e recomendações algorítmicas. Esse processo favorece a formação de bolhas informacionais e reduz a existência de experiências comunicacionais compartilhadas coletivamente. Além disso, a velocidade da circulação digital intensifica fenômenos relacionados à desinformação. Conteúdos emocionalmente apelativos tendem a se espalhar rapidamente em ambientes digitais hiperconectados, especialmente em plataformas baseadas em compartilhamento instantâneo.

7.2 Exclusão digital e desigualdade informacional

Embora o acesso à internet tenha crescido significativamente nos últimos anos, os resultados demonstram que a inclusão digital no Brasil ainda ocorre de forma desigual. O Cluster Tradicional Puro evidenciou a existência de grupos com baixa integração ao ambiente digital e forte dependência dos meios tradicionais de comunicação. Esse resultado confirma a discussão de Castells (2009) sobre desigualdade na sociedade em rede. Segundo o autor, o acesso às tecnologias digitais tornou-se elemento central de participação econômica, cultural e política na contemporaneidade.

Dessa forma, a ausência de conectividade representa não apenas limitação técnica, mas também restrição ao acesso à informação, oportunidades e participação social. Além disso, as regras de associação mostraram forte relação entre renda, escolaridade e diversidade de consumo digital. Sob a perspectiva de Bourdieu (1983), esse comportamento pode ser interpretado a partir do conceito de capital cultural. Indivíduos com maior escolaridade tendem a possuir maior capacidade de navegação, interpretação e integração aos ambientes digitais contemporâneos.

Assim, a desigualdade observada não se restringe apenas ao acesso físico à internet, mas também às competências necessárias para utilização crítica e diversificada das plataformas digitais. Os resultados demonstram que inclusão digital envolve simultaneamente: infraestrutura tecnológica, condições econômicas, escolaridade e habilidades informacionais.

7.3 Transformação do consumo audiovisual

O destaque do YouTube nos clusters digitais revela uma mudança importante no comportamento midiático contemporâneo. O consumo audiovisual sob demanda passa a competir diretamente com formatos tradicionais de comunicação linear, modificando a relação da população com o tempo, a informação e o entretenimento.

Segundo Santaella (2003), a comunicação digital contemporânea é marcada pela mobilidade, fragmentação e hipertextualidade dos conteúdos. Nesse ambiente, os usuários deixam de seguir grades fixas de programação e passam a consumir conteúdos personalizados conforme interesses individuais. O crescimento do YouTube observado neste estudo reforça esse processo. A plataforma combina: algoritmos de recomendação, comunicação audiovisual, consumo móvel, compartilhamento instantâneo e personalização de conteúdo.

Esse modelo altera profundamente as dinâmicas tradicionais da mídia. Além disso, Bauman (2001) afirma que a modernidade líquida produz relações sociais mais rápidas, flexíveis e instáveis. Esse comportamento pode ser percebido no padrão acelerado e fragmentado de consumo informacional identificado nos clusters digitais.

7.4 Mineração de dados como ferramenta de análise social

Os resultados deste estudo também demonstram o potencial da mineração de dados como instrumento de análise social e comunicacional. A utilização conjunta de algoritmos como

K-Means, Apriori e Clustering Hierárquico permitiu transformar grandes volumes de dados em padrões interpretáveis sobre comportamento midiático da população brasileira. Segundo Han, Kamber e Pei (2011), técnicas de mineração de dados possibilitam identificar estruturas ocultas em bases complexas, ampliando a capacidade analítica em cenários com grande quantidade de variáveis.

Neste trabalho, a aplicação dessas técnicas permitiu: identificar perfis distintos de consumo de mídia; compreender relações entre conectividade e desigualdade social; mapear padrões de comportamento digital; e visualizar tendências informacionais da população. Além disso, a validação cruzada entre diferentes métodos de clustering aumentou a robustez dos resultados encontrados. Dessa forma, a mineração de dados demonstrou não apenas capacidade técnica de segmentação estatística, mas também relevância como ferramenta interdisciplinar para compreensão das transformações sociais mediadas pela tecnologia.

8. CONCLUSÃO

O presente estudo analisou padrões de consumo de mídia tradicional e digital no Brasil utilizando técnicas de mineração de dados aplicadas aos microdados da pesquisa TIC Domicílios 2025 e aos indicadores do Reuters Digital News Report 2025. Os resultados evidenciaram que o ecossistema midiático brasileiro é marcado pela coexistência entre meios tradicionais e plataformas digitais, configurando um ambiente híbrido de circulação da informação.

A aplicação do algoritmo K-Means permitiu identificar quatro perfis distintos de comportamento midiático: Digital Urbano, Tradicional Puro, Digital Premium e Digital Rural. Cada agrupamento apresentou características específicas relacionadas à conectividade, utilização de plataformas digitais, escolaridade, renda e infraestrutura tecnológica. As regras de associação identificadas pelo algoritmo Apriori demonstraram forte relação entre acesso à internet, escolaridade elevada e diversidade de consumo digital. Além disso, a comparação entre K-Means e Clustering Hierárquico Ward confirmou a estabilidade estrutural dos agrupamentos encontrados, aumentando a confiabilidade analítica dos resultados.

Os dados também evidenciaram permanência de desigualdades significativas relacionadas à inclusão digital. Embora a conectividade tenha se expandido amplamente no país, parte da população ainda apresenta dependência predominante dos meios tradicionais de comunicação. Esse cenário demonstra que a transformação digital brasileira ocorre de maneira

heterogênea, coexistindo simultaneamente processos de hiperconectividade e exclusão informacional.

Sob perspectiva teórica, os resultados dialogam diretamente com os conceitos de sociedade em rede propostos por Castells (2009), convergência midiática discutida por Jenkins (2009) e cibercultura apresentada por Santaella (2003). Mais do que identificar padrões estatísticos, este estudo evidencia que o consumo de mídia reflete dinâmicas profundas de desigualdade social, transformação tecnológica e reorganização da esfera pública contemporânea.

Por fim, conclui-se que a mineração de dados demonstrou grande potencial como ferramenta de análise social e comunicacional, permitindo compreender padrões complexos de comportamento informacional em grandes bases populacionais.

9. LIMITAÇÕES DO ESTUDO

Embora os resultados tenham permitido identificar padrões relevantes sobre o consumo de mídia no Brasil, algumas limitações devem ser consideradas. A pesquisa utilizou dados autodeclarados da TIC Domicílios, sujeitos a possíveis distorções de percepção ou omissão de respostas. Além disso, parte das variáveis possuía caráter condicional, exigindo cuidados específicos durante o pré-processamento para evitar perda excessiva de registros e distorções estatísticas.

Outra limitação refere-se à simplificação necessária para aplicação dos algoritmos de mineração de dados. O processo de binarização das variáveis reduz parte da complexidade dos comportamentos sociais analisados, enquanto os algoritmos identificam padrões de similaridade sem estabelecer relações de causalidade. Também é importante considerar o caráter dinâmico do ambiente digital, no qual plataformas e hábitos de consumo se transformam rapidamente ao longo do tempo.

Apesar dessas limitações, os resultados apresentaram coerência estatística e alinhamento teórico consistente, contribuindo para a compreensão das transformações do consumo de mídia e da conectividade digital no Brasil.

10. TRABALHOS FUTUROS

Pesquisas futuras podem ampliar a análise incorporando variáveis relacionadas à confiança nas notícias, percepção de credibilidade e exposição à desinformação digital. Também podem ser realizadas análises temporais com diferentes edições da TIC Domicílios, permitindo acompanhar a evolução dos padrões de conectividade e consumo midiático no Brasil.

Além disso, estudos futuros podem explorar recortes regionais e aplicar técnicas mais avançadas de aprendizado de máquina e Processamento de Linguagem Natural para investigar fenômenos como polarização, fake news e formação de bolhas informacionais. A integração entre abordagens quantitativas e qualitativas também pode contribuir para compreensão mais aprofundada dos aspectos sociais e culturais envolvidos no consumo de mídia contemporâneo.

REFERÊNCIAS

- AGRAWAL, R.; SRIKANT, R. **Fast algorithms for mining association rules**. In: Proceedings of the 20th International Conference on Very Large Data Bases. Santiago: VLDB, 1994.
- BAUMAN, Z. **Modernidade líquida**. Rio de Janeiro: Zahar, 2001.
- BOURDIEU, P. **Os três estados do capital cultural**. In: NOGUEIRA, M. A.; CATANI, A. (Org.). Escritos de educação. Petrópolis: Vozes, 1983.
- CARRO, Rodrigo. Brazil. In: Digital News Report 2025. **Oxford: Reuters Institute for the Study of Journalism, University of Oxford**, 2025. Disponível em: [Reuters Institute – Brazil 2025](#). Acesso em: 24 maio 2026.
- CASTELLS, M. **A sociedade em rede**. 6. ed. São Paulo: Paz e Terra, 2009.
- CGI.br. Pesquisa sobre o Uso das Tecnologias de Informação e Comunicação nos Domicílios Brasileiros: TIC Domicílios 2025. **Comitê Gestor da Internet no Brasil**. São Paulo, 2025.
- CHAPMAN, P. et al. **CRISP-DM 1.0: Step-by-step data mining guide**. Chicago: SPSS Inc., 2000.
- EVERITT, B. et al. **Cluster Analysis**. 5. ed. Londres: Wiley, 2011.
- FAYYAD, U. et al. **From data mining to knowledge discovery in databases**. AI Magazine, v. 17, n. 3, p. 37–54, 1996.
- HAN, J.; KAMBER, M.; PEI, J. **Data Mining: Concepts and Techniques**. 3. ed. Burlington: Morgan Kaufmann, 2011.
- JENKINS, H. **Cultura da convergência**. 2. ed. São Paulo: Aleph, 2009.
- KUROSE, J.; ROSS, K. **Redes de computadores e a internet: uma abordagem top-down**. 5. ed. São Paulo: Pearson, 2010.

LÉVY, P. **Cibercultura**. São Paulo: Editora 34, 1999.

MACQUEEN, J. **Some methods for classification and analysis of multivariate observations**. In: Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. Berkeley: University of California Press, 1967.

NEWMAN, Nic et al. Digital News Report 2025. **Oxford: Reuters Institute for the Study of Journalism, University of Oxford, 2025**. Disponível em: [Reuters Institute Digital News Report 2025](#). Acesso em: 25 maio 2026.

SANTAELLA, L. **Culturas e artes do pós-humano: da cultura das mídias à cibercultura**. São Paulo: Paulus, 2003.

TANENBAUM, A. **Redes de computadores**. 4. ed. São Paulo: Pearson, 2003.